Rapport de Mini-Projet : Planification d'expériences sur un domaine contraint

Emmanuel Abondo Owona

20 février 2026

Table des matières

1 Partie I : Préliminaires théoriques **2**
1.1 Question 1 : Loi de Dirichlet et méthode de rejet 2
1.2 Question 2 : Transformation de l'Hypercube vers le Simplexe 2

2 Partie II : Plans d'expériences naïfs **3**
2.1 Comparaison théorique : Aléatoire pur vs Stratifié 3
2.2 Analyse des résultats empiriques (n et d) 3

3 Partie III : Plan Maximin Packing Géométrique **3**
3.1 Question 1 : Formalisation et Convergence du critère lissé 3
3.2 Analyse des résultats de l'optimisation 4

4 Partie IV : Plan Minimax Covering du Simplexe **4**
4.1 Question 1 : Conservation de la contrainte par l'algorithme de Lloyd 4

1 Partie I : Préliminaires théoriques

1.1 Question 1 : Loi de Dirichlet et méthode de rejet

Soient $Y_1, \ldots, Y_d$ des variables aléatoires indépendantes et identiquement distribuées (i.i.d.) suivant une loi exponentielle de paramètre 1 ($\mathcal{E}(1)$). La densité conjointe du vecteur $Y = (Y_1, \ldots, Y_d)$ sur $\mathbb{R}_+^d$ est donnée par :

$$f_Y(y_1, \ldots, y_d) = \prod_{i=1}^{d} e^{-y_i} = \exp\left(-\sum_{i=1}^{d} y_i\right) \tag{1}$$

Considérons le changement de variables suivant :

$$S = \sum_{i=1}^{d} Y_i \quad \text{et} \quad X_i = \frac{Y_i}{S} \quad \text{pour } i = 1, \ldots, d \tag{2}$$

Le vecteur $X = (X_1, \ldots, X_d)$ appartient au simplexe standard Δ_d car $\sum X_i = 1$ et $X_i \geq 0$.

Pour déterminer la loi de X, effectuons un changement de variables difféomorphique Φ : $(y_1, \ldots, y_d) \mapsto (x_1, \ldots, x_{d-1}, s)$. L'inverse Φ^{-1} est donné par $y_i = sx_i$ pour $i < d$ et $y_d = s(1 - \sum_{i=1}^{d-1} x_i)$. Le déterminant du Jacobien de cette transformation est proportionnel à s^{d-1}.

La densité conjointe de $(X_1, \ldots, X_{d-1}, S)$ s'écrit alors :

$$f_{X,S}(x, s) \propto s^{d-1} \cdot \exp(-s) \cdot 1_{\Delta_d}(x) \tag{3}$$

On reconnait ici que S suit une loi Gamma $\Gamma(d, 1)$ et que la densité de X ne dépend pas de x (terme constant sur le simplexe). Par conséquent, X suit une loi uniforme sur le simplexe Δ_d, ce qui correspond à la loi de Dirichlet $Dir(1, \ldots, 1)$.

1.2 Question 2 : Transformation de l'Hypercube vers le Simplexe

On définit la transformation $T : [0, 1]^{d-1} \to \Delta_d$ par récurrence (méthode dite du *stick-breaking*) :

$$\begin{aligned}
x_1 &= 1 - u_1^{\frac{1}{d-1}} \\
x_k &= \left(1 - \sum_{j=1}^{k-1} x_j\right)\left(1 - u_k^{\frac{1}{d-k}}\right) \quad \text{pour } k = 2, \ldots, d-1 \\
x_d &= 1 - \sum_{j=1}^{d-1} x_j
\end{aligned}$$

Preuve de l'uniformité : Soit $U \sim \mathcal{U}([0, 1]^{d-1})$. L'objectif est de montrer que $X = T(U)$ est uniforme sur Δ_d. Considérons les variables intermédiaires $V_k = u_k^{\frac{1}{d-k}}$. La fonction de répartition de V_k est $P(V_k \leq v) = P(u_k \leq v^{d-k}) = v^{d-k}$. La densité de V_k est donc $f_{V_k}(v) = (d-k)v^{d-k-1}$.

Cette transformation correspond géométriquement à trier $d-1$ variables uniformes indépendantes. Soient $Z_1, \ldots, Z_{d-1}$ i.i.d. $\mathcal{U}([0, 1])$. Notons $Z_{(1)} \leq \cdots \leq Z_{(d-1)}$ leurs statistiques d'ordre. On sait classiquement que les espacements définis par $X_1 = Z_{(1)}$, $X_2 = Z_{(2)} - Z_{(1)}$, $\ldots$, $X_d = 1 - Z_{(d-1)}$ suivent une loi uniforme sur le simplexe Δ_d. La bijection T construit exactement ces espacements à partir des variables U_i. Ainsi, l'image de l'hypercube par T couvre uniformément le simplexe.

2 Partie II : Plans d'expériences naïfs

2.1 Comparaison théorique : Aléatoire pur vs Stratifié

Bien que les méthodes de Dirichlet et de l'Hypercube Latin (LHS) soient toutes deux stochastiques, elles diffèrent fondamentalement par la nature de l'aléatoire utilisé :

— **Méthode de Dirichlet (Monte Carlo pur) :** Les points sont tirés de manière **indépendante** et identiquement distribuée. Comme dans tout processus purement aléatoire, cela peut conduire par hasard à la formation d'amas de points (*clusters*) et laisser de grandes zones vides.

— **Hypercube Latin (Hasard stratifié) :** Cette méthode introduit des **contraintes structurelles**. L'espace est divisé en sous-intervalles équiprobables, et l'algorithme impose qu'un seul point soit placé par hyper-rangée et hyper-colonne. L'aléatoire intervient uniquement dans le mélange des coordonnées. C'est une technique de **réduction de variance** qui garantit une meilleure répartition (*space-filling*) à taille d'échantillon égale.

2.2 Analyse des résultats empiriques (n et d)

Nous avons évalué la qualité du remplissage via deux critères : la distance minimale (ϕ, critère de *packing*) et le rayon de couverture (ψ, critère de *covering*).

1. L'impact du nombre de points (n)

À dimension fixée ($d = 3$), nous faisons varier le nombre de points.

— **Distance Minimale (ϕ) :** Plus on ajoute de points, plus ils sont serrés (la distance diminue). Cependant, la courbe **LHS** reste systématiquement **au-dessus** de celle de Dirichlet. Le LHS évite les « amas » typiques du hasard pur.

— **Rayon de Couverture (ψ) :** Plus n augmente, mieux on couvre l'espace (le rayon diminue). La courbe **LHS** est **en dessous** de Dirichlet, ce qui signifie qu'il laisse moins de « grands trous » vides dans le simplexe.

2. L'impact de la dimension (d) : La Malédiction de la Dimension

À nombre de points fixé ($n = 50$), nous faisons varier la dimension.

— **Distance Minimale (ϕ) :** Elle a tendance à augmenter avec la dimension. Dans un espace vaste, les points sont statistiquement plus éloignés les uns des autres (souvent isolés sur les sommets ou les arêtes).

— **Rayon de Couverture (ψ) :** Le rayon **augmente drastiquement** dès que d dépasse 5 ou 6. C'est la **« Malédiction de la Dimension »**. Avec seulement 50 points, il est impossible de couvrir correctement un espace de dimension 10.

3 Partie III : Plan Maximin Packing Géométrique

3.1 Question 1 : Formalisation et Convergence du critère lissé

Le critère Maximin cherche à maximiser la distance minimale $\phi_{Mm}(\mathcal{X}) = \min_{i<j} \|x^{(i)} - x^{(j)}\|$. Pour utiliser des méthodes de gradient, on utilise une approximation régularisée ϕ_p :

$$\phi_p(\mathcal{X}) = \left(\sum_{1 \leq i < j \leq n} \frac{1}{\|x^{(i)} - x^{(j)}\|^p} \right)^{-1/p} \tag{4}$$

Preuve de la convergence : Nous cherchons la limite de $\phi_p(\mathcal{X})$ quand $p \to +\infty$. Notons $d_{\min} = \phi_{Mm}(\mathcal{X})$. Dans la somme $S_p = \sum d_{ij}^{-p}$, le terme dominant est $d_{\min}^{-p}$. On encadre S_p :

$$d_{\min}^{-p} \leq \sum_{i<j} d_{ij}^{-p} \leq K \cdot d_{\min}^{-p} \tag{5}$$

où $K = \binom{n}{2}$ est le nombre de paires. En élevant à la puissance $-1/p$ (fonction décroissante), on obtient :

$$d_{\min} \geq \phi_p(\mathcal{X}) \geq K^{-1/p} \cdot d_{\min} \tag{6}$$

Lorsque $p \to +\infty$, $K^{-1/p} \to 1$. D'après le théorème des gendarmes, $\lim_{p\to+\infty} \phi_p(\mathcal{X}) = d_{\min}$.

3.2 Analyse des résultats de l'optimisation

L'optimisation numérique du critère ϕ_p permet d'obtenir des plans quasi-optimaux.

— **Gain apporté :** Les plans optimisés présentent une distance minimale (ϕ) nettement supérieure à celle des plans LHS ou aléatoires. L'algorithme « pousse » activement les points les uns contre les autres pour maximiser l'écartement.

— **Limites :** Malgré l'optimisation, le rayon de couverture (ψ) explose toujours en haute dimension. L'optimisation améliore la répartition locale (packing) mais ne peut compenser le volume exponentiel de l'espace (problème de covering) sans augmenter n.

4 Partie IV : Plan Minimax Covering du Simplexe

4.1 Question 1 : Conservation de la contrainte par l'algorithme de Lloyd

Nous cherchons à vérifier que si un plan initial est dans le simplexe Δ_d, les itérations de Lloyd maintiennent les points dans Δ_d.

Soit $\mathcal{X} = \{x^{(1)}, \ldots, x^{(n)}\}$ le plan courant avec $x^{(j)} \in \Delta_d$. L'algorithme de Lloyd contraint construit les cellules de Voronoï restreintes au domaine :

$$\mathcal{C}_j = V_j \cap \Delta_d = \{y \in \Delta_d \mid \|y - x^{(j)}\| \leq \|y - x^{(k)}\|, \forall k \neq j\} \tag{7}$$

Nous savons que :

1. Le simplexe standard Δ_d est un ensemble **convexe** (intersection de demi-espaces et d'un hyperplan).
2. Une cellule de Voronoï standard V_j (dans $\mathbb{R}^d$) est un polyèdre **convexe**.
3. L'intersection de deux ensembles convexes est elle-même **convexe**.

Par conséquent, la cellule restreinte $\mathcal{C}_j$ est un ensemble convexe inclus dans Δ_d.

L'étape de mise à jour de l'algorithme consiste à remplacer $x^{(j)}$ par le barycentre (ou centroïde) de sa cellule $\mathcal{C}_j$. Or, d'après les propriétés de la géométrie convexe, **le barycentre d'un ensemble convexe borné appartient toujours à cet ensemble**.

Ainsi, le nouveau point $x_{\text{new}}^{(j)}$ appartient à $\mathcal{C}_j$. Puisque $\mathcal{C}_j \subset \Delta_d$, on a nécessairement $x_{\text{new}}^{(j)} \in \Delta_d$. La contrainte est donc automatiquement préservée par l'algorithme sans nécessiter de projection supplémentaire.